

# Optimizacija težina neuronske mreže genetskim algoritmom

Seminarski rad u okviru kursa

Računarska inteligencija

Matematički fakultet

Ivana Ivanović, Ivana Cvetkoski

mi16120@alas.matf.bg.ac.rs, mi16065@alas.matf.bg.ac.rs

## Sadržaj

<b>1</b>	<b>Uvod</b>	<b>2</b>
<b>2</b>	<b>Genetski algoritam</b>	<b>2</b>
<b>3</b>	<b>Neuronske mreže</b>	<b>2</b>
<b>4</b>	<b>Algoritam</b>	<b>3</b>
<b>5</b>	<b>Rezultati</b>	<b>4</b>
	<b>Literatura</b>	<b>5</b>

# 1 Uvod

Kombinovanje neuronske mreže sa evolucionim algoritmima vodi evolucionoj veštačkoj neuronskoj mreži. Podešavanje težina neuronske mreže je jedan od najvažnijih koraka u korišćenju neuronskih mreža. Poenta ovog koraka jeste postavljanje najboljih težina u mreži za dati trening skup podataka, tako da mreža može što preciznije da izvrši klasifikaciju ili regresiju u zavisnosti od datog problema. Za traženje optimalnih težina mogu da se koriste različiti algoritmi, mi smo u ovom radu optimizaciju vršile uz pomoć genetskog algoritma.

## 2 Genetski algoritam

Genetski algoritam (GA) je razvijen u Americi 1970-ih godina. Predstavlja populacionu meta-heuristiku koja, kao i ostale nije previše brza, ali predstavlja dobru heuristiku za rešavanje kombinatornih problema. Originalni genetski algoritam se drugačije naziva i kanonski algoritam, ali pored njega postoji mnogo varijacija koje se dobijaju promenom mutacija, reprezentacija, ukrštanja i selekcija. Glavne primene su kod problema u diskretnom domenu.

Rad GA se može opisati pomoću sledećih koraka:

1. Definisanje svih potrebnih parametara problema i GA
2. Formiranje populacije
3. Dekodiranje hromozoma — ovaj korak se javlja samo kod binarnih GA
4. Izračunavanje fitness funkcije, odnosno određivanje cena hromozoma
5. Odabir selekcije hromozoma koji će opstati za ukrštanje
6. Ukrštanje — obično se iz boljeg dela populacije odabiru roditelji koji će na neki način ukrstiti svoj genetski materijal i dati jednog ili više potomaka koji obično zamene nekog od lošijih hromozoma
7. Mutacije, pri kojima se menja genetski sadržaj hromozoma
8. Ispitivanje konvergencije, da bi se utvrdilo da li ima osnova da se tok algoritma prekine. Ukoliko nije ispunjen uslov konvergencije, vratiti se na korak 3 odnosno 4.

## 3 Neuronske mreže


Ljudski mozak može da prepozna oblike, ima percepciju i motoriku. Pored ovih karakteristika, druge, kao što su sposobnost učenja, pamćenja i dalje generalizovanja, podstakla su istraživanja u algoritamskom modeliranju bioloških neuronskih sistema – veštačkim neuronskim mrežama (NN).

Imamo između 10 i 500 milijardi neurona i 60 triliona sinapsi, zbog čega ne možemo da modeliramo mozak, ali su trenutni uspesi neuronskog modeliranja vezani za male veštačke neuronske mreže koje služe za rešavanje određenog zadatka. Neuron se sastoji od ćelijskog tela, dendrita i aksona. Neuroni su masovno međusobno povezani, gde je međusobna veza akson jednog neurona i dendrit drugog neurona. Ova veza se zove sinapsa i ona je zaslužna za pamćenje. Svaki impuls u sinapsi izaziva lučenje male količine neurotransmitera. Neuroni se ne regenerišu i to u kombinaciji sa sinapsama omogućava pamćenje. Signali se kreću od dendrita kroz ćelijsko telo do aksona, a potom se signal širi na ostale povezane dendrite. Neuron može da suzbije ili pojača jačinu signala.

Veštački neuroni predstavljaju model bioloških neurona. Svaki prima signal od okruženja ili drugog neurona, prikuplja signale i kada se 'ispali' prenosi signal na sve povezane neurone. U ovom slučaju ispaljivanje i jačina signala su kontrolisani formulom.

- $I$  - broj ulaznih signala
- $z$  - ulazni signal
- $v$  - težine pridružene ulaznim sig pri čemu je pozitivna težina ekscitacija, a negativna inhibicija
- $o$  - izlazni signal
- $net$  - baziran na proizvodu omogućava veći informacioni kapacitet
- $\theta$  - slobodan član

Veštačka neuronska mreža je slojevita mreža veštačkih neurona. Neuronska mreža se može sastojati od ulaznog sloja, skrivenih slojeva (koji može izostatiti, ili ih može biti više) i izlaznog sloja.



Slika 1

Vrste mreža:

1. Jednoslojne
2. Višeslojne mreže sa propagacijom unapred
3. Temporalne i rekurentne
4. Samoorganizujuće
5. Kombinovane

Primenjuju se u medicinskoj dijagnostici, prepoznavanju zvuka, procesiranju slika, predviđanje u analizi vremenskih serija, kontroli robota, klasifikaciji podataka, kompresiji podataka...

## 4 Algoritam

Prilagođavanje vektora težina u neuronskim mrežama prema vrednostima ulaznih vektora je najvažniji zadatak neuronske mreže, kako bi mreža mogla da 'nauči' odgovarajuća pravila o datom skupu. U našem projektu prilagođavanje težina smo vršile pomoću genetskog algoritma.

Svaka jedinka je definisana preko vektora vrednosti koje predstavljaju težine neuronske mreže. Pored toga, svaka jedinka mora da ima pristup modelu mreže i treninig podacima. Za potrebe računanja fitness vrednosti jedinki morale smo da transformišemo oblik u kome su zapisane težine, jer smo prilagođenost jedinke ocenjivale kao preciznost koju nam vraća evaluacija modela sa njenim težinama.

Kako bi najbolje jedinke imale veću verovatnoću u učestvovanju u ostavljanju potomaka, koristile smo ruletsku selekciju roditelja. Sledeći korak je dvopoziciono ukrštanje roditelja. Na slučajan način smo izabrale dve tačke, na tim mestima podelile oba roditelja na tri dela. Zamenom središnjih delova dobile smo dva nova deteta. Mutaciju smo vršile tako što smo sa verovatnoćom od 0.05 menjale svaku pojedinačnu težinu u jedinki, jednostavnom zamenom sa nekom slučajnom vrednošću. U slučaju da se vrši mutacija nad jedinkom koja spada u 10 najgorih u generaciji ova verovatnoća bi se povećala duplo, i iznosila bi 0.1.

Naša neuronska mreža je potpuno povezana i sastoji se iz 3 sloja, ulaznog, skrivenog i izlaznog. Središnji sloj ima 100 neurona i koristi relu aktivacionu funkciju, dok se na izlaznom sloju koristi sigmoidna funkcija, a broj neurona zavisi od klasa koji ima dati skup. Podatke smo podelile na test, koji čine jedna trećina ukupnih podataka, i ostatak koji predstavlja trening skup, nad kome je vršena optimizacija.


Na samom početku algoritma smo ciljne vrednosti pretvorile u kategoričke i normalizovale ulazne podatke. Zatim smo napravile mrežu, kao što smo opisale iznad. Potom smo napravile populaciju od 30 jedinki, kojima su težine slučajno dodeljene vrednosti u opsegu od -1 do 1. U ovom trenutku kreće da se izvršava genetski algoritam, tj. ulazimo u petlju kroz koju prolazimo 150 puta. Takođe, ovde smo koristile i elitizam, tako da uvek 20% najboljih jedinki prebacujemo u sledeću populaciju. Dok prolazimo kroz iteracije i izvršavamo nabrojane funkcije za genetski algoritam, računamo i pamtimo najbolju jedinku. To je ona jedinka koja ima najveću preciznost.

Preciznosti najbolje jedinke iz svih generacija na trening i test skupu predstavljaju izlaz ove naše funkcije koja optimizuje težinu neuronske mreže.

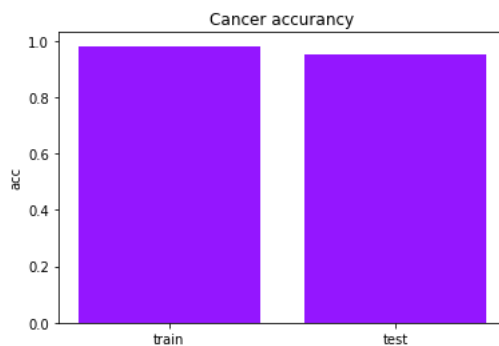
## 5 Rezultati

Kako radi naša optimizacija testirale smo klasifikacijom podataka iz tri skupa. Prvi skup je skup Iris, sačinjen je od podataka 150 cvetova, za svaki cvet je izmerena dužina i širina latice i dužina i širina čašičnog lista. Na osnovu toga treba da klasifikujemo kojoj od tri vrste irisa cvetovi pripadaju. U ovom slučaju bilo je potrebno da namestimo 803 parametra. Drugi skup je Breast cancer, koji sadrži podatke o 569 instanci. Svaka je opisana sa 30 atributa i treba da se klasifikuje u benigne ili maligne. Broj težina u ovoj mreži je 3202. I na kraju treći skup, skup Wine u kome su vrednosti o 178 vina. Svaki je opisan sa 13 atributa i treba da se klasifikuje u jednu od 3 klasi vina. Za poslednji skup dužina vektora težine je iznosila 1702.

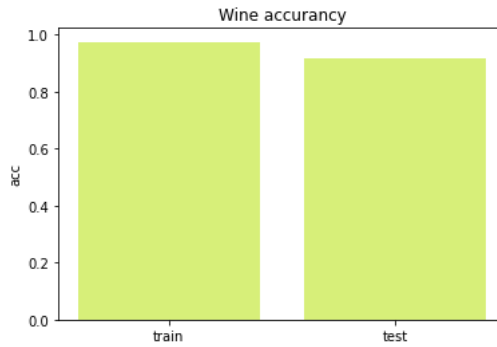
Preciznosti koje smo dobile na trening i test skupovima za sva tri skupa podataka prelazi 90%, tako da možemo reći da je klasifikacija u sva tri slučaja prilično dobra. U slučaju skupa Iris preciznost na trening podacima iznosi 97%, a na test podacima iznosi 96%. Preciznost trening skupa je 98%, a test skupa je 95% za skup Breast cancer. Na kraju, preciznost na skupu Wine za trening podatke iznosi 97%, a za test podatke 91%. Odnos vrednosti na trening i test podacima za svaki od skupova se može videti na slikama ispod.



Slika 2: Preciznost na skupu Iris



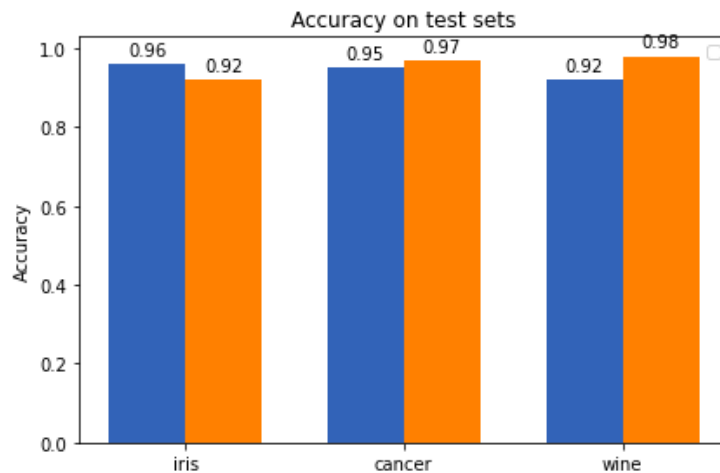
Slika 3: Preciznost na skupu Breast cancer



Slika 4: Preciznost na skupu Wine

Našu preciznost smo poredili sa rezultatima funkcije koja je optimizovala težine neuronske mreže Adamovim optimizatorom. Adam je algoritam za optimizaciju koji se može koristiti umesto klasičnog postupka stohastičkog gradijentnog spusta za ažuriranje težina mreže iterativno na osnovu trening podataka. Struktura mreže je ista, sastoji se iz tri potpuno povezana sloja, u kojoj središnji sloj ima 100 čvorova.

Na sledećoj slici prikazana je preciznost dobijena našom optimizacijom (genetskim algoritmom) i korišćenjem Adamovog optimizatora na test skupovima za sva tri pomenuta skupa.



Slika 5: Poređenje preciznosti optimizacijom genetskim algoritmom i Adamom

Kao što možemo da vidimo, iako su vrednosti blizu, u dva od tri skupa Adamov optimizator je dao bolju preciznost. Ti skupovi su Breast cancer i Wine, dok je na skupu Iris naša optimizacija dala bolji rezultat. Takođe, moramo da napomenemo da su sve preciznosti vrlo zadovoljavajuće.

## Literatura

- [1] Andries P. Engelbrecht, John Willy and Sons *Computational Intelligence - An Introduction*. 2007.
- [2] Richa Mahajan, Gaganpreet Kaur. *Neural Networks using Genetic Algorithms*. International Journal of Computer Applications (0975 – 8887) Volume 77– No.14, September 2013
- [3] Yu-Tzu C-hang, Jinn Lin, Jiann-Shing Shieh, and Maysam F. Abbod *Optimization the Initial Weights of Artificial Neural Networks via Genetic Algorithm Applied to Hip Bone Fracture Prediction*. Cambridge: MIT Press, 2004.